

WiFi DensePose: Полное математическое обоснование

Проект WiFi DensePose

27 июня 2026 г.

Аннотация

Данный документ представляет собой исчерпывающее математическое описание проекта WiFi DensePose. В нём последовательно излагаются физические принципы распространения радиоволн и модель многолучевого канала, математический аппарат формирования Channel State Information (CSI) в MIMO-OFDM системах, методы предобработки сигнала, а также архитектура и математика нейросетевого преобразователя, который отображает CSI-данные в 3D-скелет человека. Все формулы и выводы базируются на актуальных научных исследованиях и открытых реализациях.

1 Физическая модель радиоканала

1.1 Модель многолучевого распространения

В типичной indoor-среде сигнал от передатчика (TX) к приёмнику (RX) распространяется по множеству путей из-за отражений, дифракции и рассеяния радиоволн. Комплексный сигнал на приёмнике является суперпозицией всех этих компонент:

$$V = \sum_{n=1}^N \|V_n\| e^{-j\phi_n}, \quad (1)$$

где $\|V_n\|$ и ϕ_n — амплитуда и фаза n -й многолучевой компоненты, а N — их общее число. Уровень принимаемого сигнала (RSSI) в децибелах определяется как:

$$\text{RSSI} = 10 \log_{10} (\|V\|^2). \quad (2)$$

Однако RSSI не отражает многолучевую структуру канала и чувствителен к интерференции. Для полного описания канала используется его импульсная характеристика (Channel Impulse Response, CIR):

$$h(t) = \sum_{n=1}^N \alpha_n e^{-j\phi_n} \delta(t - \tau_n), \quad (3)$$

где α_n , ϕ_n и τ_n — комплексное затухание, фаза и временная задержка для n -го пути, а $\delta(\cdot)$ — дельта-функция Дирака.

1.2 Частотная характеристика канала (CFR)

В частотной области канал описывается частотной характеристикой (Channel Frequency Response, CFR), которая является преобразованием Фурье от CIR:

$$H(f) = \mathcal{F}\{h(t)\} = \sum_{n=1}^N \alpha_n e^{-j\phi_n} e^{-j2\pi f\tau_n}. \quad (4)$$

CFR состоит из амплитудной и фазовой характеристик и обеспечивает высокое разрешение канала.

2 Математическая модель Channel State Information (CSI)

2.1 CSI в MIMO-OFDM системах

В современных стандартах Wi-Fi (IEEE 802.11n/ac) используется технология MIMO-OFDM. Система с N_{TX} передающими и N_{RX} приёмными антеннами для каждой поднесущей k описывается уравнением:

$$\mathbf{y}_k = \mathbf{H}_k \mathbf{x}_k + \mathbf{n}_k, \quad (5)$$

где:

- $\mathbf{y}_k \in \mathbb{C}^{N_{RX}}$ — вектор принятых сигналов на поднесущей k ,
- $\mathbf{x}_k \in \mathbb{C}^{N_{TX}}$ — вектор переданных символов,
- $\mathbf{n}_k \in \mathbb{C}^{N_{RX}}$ — вектор шума,
- $\mathbf{H}_k \in \mathbb{C}^{N_{RX} \times N_{TX}}$ — матрица CSI для поднесущей k .

CSI является оценкой этой матрицы, получаемой на основе известных обучающих символов (Long Training Fields, LTF) в преамбуле пакета.

2.2 Представление CSI

Каждый элемент матрицы CSI для i -й поднесущей представляет собой комплексное число:

$$H_i = |H_i| e^{j\angle H_i}, \quad (6)$$

где $|H_i|$ — амплитуда, а $\angle H_i$ — фаза частотной характеристики канала для i -й поднесущей.

Таким образом, CSI — это многомерный дескриптор, кодирующий амплитудную и фазовую информацию по антеннам и поднесущим, отражая динамику окружающей среды.

2.3 Предобработка CSI

Сигнал содержит шумы, поэтому применяется фильтрация. В проекте используется фильтр Баттерворта 4-го порядка, который обеспечивает максимально плоскую частотную характеристику в полосе пропускания. Передаточная функция такого фильтра в общем виде:

$$|H(\omega)|^2 = \frac{1}{1 + (\omega/\omega_c)^{2n}}, \quad (7)$$

где $n = 4$ — порядок фильтра, ω_c — частота среза.

3 Математика нейросетевого преобразователя

3.1 Входной тензор

Входными данными для нейросети является тензор CSI-амплитуд размерности:

$$\mathcal{X} \in \mathbb{R}^{A \times S \times T}, \quad (8)$$

где $A = 3$ — число пар антенн, $S = 114$ — число поднесущих, $T = 10$ — число временных срезов при частоте дискретизации 100 Гц.

3.2 Архитектура Transformer

Архитектура модели базируется на Transformer-энкодере.

3.2.1 Линейная проекция

Каждый из $T = 10$ временных срезов проецируется в $D = 256$ -мерное пространство:

$$\mathbf{e}_t = \mathbf{W}_e \mathbf{x}_t + \mathbf{b}_e, \quad t = 1, \dots, T, \quad (9)$$

где $\mathbf{x}_t \in \mathbb{R}^{A \cdot S}$ — векторизированный срез размерности 342, $\mathbf{W}_e \in \mathbb{R}^{D \times (A \cdot S)}$ и $\mathbf{b}_e \in \mathbb{R}^D$ — обучаемые параметры проекции.

3.2.2 Transformer-энкодер

Полученные T токенов $\{\mathbf{e}_t\}_{t=1}^T$ обрабатываются 4-слойным Transformer-энкодером с 8 головами внимания. Слой внимания вычисляется как:

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax} \left(\frac{\mathbf{Q}\mathbf{K}^T}{\sqrt{d_k}} \right) \mathbf{V}, \quad (10)$$

где $\mathbf{Q}, \mathbf{K}, \mathbf{V}$ — матрицы запросов, ключей и значений, полученные линейными проекциями от токенов, а d_k — размерность ключей.

3.2.3 Пулдинг внимания по времени

Ключевым нововведением является использование механизма внимания для агрегации информации по времени, что позволило сохранить временную динамику (в отличие от простого усреднения):

$$\mathbf{z} = \sum_{t=1}^T \alpha_t \mathbf{h}_t, \quad (11)$$

где $\mathbf{h}_t$ — выход энкодера для t -го токена, а веса внимания α_t вычисляются как:

$$\alpha_t = \frac{\exp(\mathbf{w}^T \mathbf{h}_t)}{\sum_{j=1}^T \exp(\mathbf{w}^T \mathbf{h}_j)}. \quad (12)$$

3.3 Декодер и оценка позы

Агрегированный вектор $\mathbf{z}$ подаётся в MLP-голову для получения 17 ключевых точек в формате COCO:

$$\hat{\mathbf{y}} = \text{MLP}(\mathbf{z}), \quad \hat{\mathbf{y}} \in \mathbb{R}^{17 \times 2}. \quad (13)$$

Далее следует этап уточнения на основе графа скелета (skeleton-graph refinement), использующий графовую свёртку по топологии костей COCO для обеспечения анатомической согласованности.

4 Метрики оценки точности

Для оценки качества модели используется метрика torso-PCK@20 (Percentage of Correct Keypoints). Ключевая точка считается правильной, если расстояние между предсказанной и истинной позицией, нормализованное на длину торса, меньше 0.2:

$$\text{PCK@0.2} = \frac{1}{17} \sum_{i=1}^{17} \mathbb{I} \left(\frac{\|\hat{\mathbf{p}}_i - \mathbf{p}_i\|_2}{\|\mathbf{p}_{\text{right shoulder}} - \mathbf{p}_{\text{left hip}}\|_2} < 0.2 \right). \quad (14)$$

Достигнутая точность на бенчмарке MM-Fi составляет 82.69% для одной модели и 83.59% для ансамбля из трёх моделей с тестовыми аугментациями (ТТА).